

HW2 中文详解

00103335: 深度学习与强化学习

2026 年秋季

本文件按原题顺序解释每一步推导。原题见同目录的 `hw2.pdf`; 英文解答见 `solution.pdf`。所有范数都是欧氏范数。推导只使用题设条件, 不额外假设二阶可微或梯度 Lipschitz 连续。

1 可微凸函数的三个等价条件

题目给定可微函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$, 要求证明以下条件等价:

- (i) $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y), \quad 0 < \lambda < 1;$
- (ii) $f(y) \geq f(x) + \nabla f(x)^\top (y - x);$
- (iii) $(\nabla f(y) - \nabla f(x))^\top (y - x) \geq 0.$

三式分别表达凸组合不等式、一阶支撑不等式、梯度的单调性。下面证明 (i) $\Leftrightarrow$ (ii) 和 (ii) $\Leftrightarrow$ (iii), 这就把三个条件全部连接起来。

(i) $\Rightarrow$ (ii): 让凸组合点趋近端点

第一步: 沿 x 到 y 的线段取点。固定 x, y , 令 $z_t = x + t(y - x) = (1 - t)x + ty$, 其中 $0 < t < 1$ 。对 z_t 使用凸性, 得到

$$f(x + t(y - x)) \leq (1 - t)f(x) + tf(y).$$

两边减去 $f(x)$, 右侧成为 $(1 - t)f(x) + tf(y) - f(x) = t(f(y) - f(x))$ 。再除以正数 t :

$$\frac{f(x + t(y - x)) - f(x)}{t} \leq f(y) - f(x).$$

第二步: 用可微性计算差商极限。当 $t \downarrow 0$ 时, 左侧趋于 f 在 x 沿 $y - x$ 的方向导数。由于 f 可微, 该方向导数等于 $\nabla f(x)^\top (y - x)$, 所以

$$\nabla f(x)^\top (y - x) \leq f(y) - f(x).$$

把 $f(x)$ 移到右侧即为 (ii)。这一步只用了可微性, 没有使用 Hessian。

(ii) $\Rightarrow$ (i): 在中间点使用两个支撑不等式

令 $z = \lambda x + (1 - \lambda)y$ 。把 (ii) 的基点取为 z ，目标点分别取为 x 和 y ，得到

$$\begin{aligned}f(x) &\geq f(z) + \nabla f(z)^\top (x - z), \\f(y) &\geq f(z) + \nabla f(z)^\top (y - z).\end{aligned}$$

第一式乘以 $\lambda > 0$ ，第二式乘以 $1 - \lambda > 0$ ，再相加：

$$\begin{aligned}\lambda f(x) + (1 - \lambda)f(y) &\geq [\lambda + (1 - \lambda)]f(z) \\&\quad + \nabla f(z)^\top [\lambda(x - z) + (1 - \lambda)(y - z)].\end{aligned}$$

梯度项中的向量恰好等于零，因为

$$\lambda(x - z) + (1 - \lambda)(y - z) = \lambda x + (1 - \lambda)y - [\lambda + (1 - \lambda)]z = z - z = 0.$$

于是 $\lambda f(x) + (1 - \lambda)f(y) \geq f(z)$ ，即 (i)。选取 z 为基点的目的，就是让这两个一阶项在加权相加后抵消。

(ii) $\Rightarrow$ (iii): 交换两点后相加

对 (x, y) 和 (y, x) 分别使用 (ii)：

$$\begin{aligned}f(y) - f(x) &\geq \nabla f(x)^\top (y - x), \\f(x) - f(y) &\geq \nabla f(y)^\top (x - y).\end{aligned}$$

相加后左侧为零。右侧利用 $x - y = -(y - x)$ 合并：

$$0 \geq (\nabla f(x) - \nabla f(y))^\top (y - x).$$

两边乘以 -1 ，不等号反向，得到

$$(\nabla f(y) - \nabla f(x))^\top (y - x) \geq 0.$$

(iii) $\Rightarrow$ (ii): 沿线段应用一元中值定理

当 $x = y$ 时，(ii) 显然为等式。下面设 $x \neq y$ ，令 $h = y - x$ 、 $g(t) = f(x + th)$ 。因为 f 可微， g 在 $[0, 1]$ 上连续、在 $(0, 1)$ 上可微，且由链式法则

$$g'(t) = \nabla f(x + th)^\top h.$$

一元中值定理保证存在 $c \in (0, 1)$ ，使

$$f(y) - f(x) = g(1) - g(0) = g'(c)(1 - 0) = \nabla f(x + ch)^\top h.$$

对两点 x 、 $x + ch$ 使用 (iii)：

$$(\nabla f(x + ch) - \nabla f(x))^\top (ch) \geq 0.$$

因为 $c > 0$, 可以除以 c , 得到

$$\nabla f(x + ch)^\top h \geq \nabla f(x)^\top h.$$

结合中值定理的等式, $f(y) - f(x) \geq \nabla f(x)^\top (y - x)$, 即 (ii)。这里使用中值定理, 只要求 g 连续和可微, 不需要先假设梯度连续。

2 强凸性的四个等价条件

题目将 μ -强凸性定义为

$$g(x) := f(x) - \frac{\mu}{2} \|x\|^2 \quad \text{是凸函数,} \quad \mu > 0.$$

核心做法是把第 1 题的三个凸性条件应用于 g 。首先, $\|x\|^2 = \sum_{i=1}^d x_i^2$, 故

$$\nabla \left(\frac{\mu}{2} \|x\|^2 \right) = \mu x, \quad \nabla g(x) = \nabla f(x) - \mu x.$$

(i) $\Leftrightarrow$ (ii): 凸组合中的二次项差

第一步: 写出 g 的凸组合不等式。 设 $z = \alpha x + (1 - \alpha)y$, $0 < \alpha < 1$ 。 g 凸等价于

$$g(z) \leq \alpha g(x) + (1 - \alpha)g(y).$$

代入 g 的定义:

$$f(z) - \frac{\mu}{2} \|z\|^2 \leq \alpha f(x) + (1 - \alpha)f(y) - \frac{\mu}{2} (\alpha \|x\|^2 + (1 - \alpha) \|y\|^2).$$

把左侧二次项移到右侧后,

$$f(z) \leq \alpha f(x) + (1 - \alpha)f(y) - \frac{\mu}{2} D,$$

其中 $D = \alpha \|x\|^2 + (1 - \alpha) \|y\|^2 - \|z\|^2$ 。

第二步: 逐项展开 D 。 由内积的双线性,

$$\|\alpha x + (1 - \alpha)y\|^2 = \alpha^2 \|x\|^2 + 2\alpha(1 - \alpha)x^\top y + (1 - \alpha)^2 \|y\|^2.$$

于是

$$\begin{aligned} D &= (\alpha - \alpha^2) \|x\|^2 + ((1 - \alpha) - (1 - \alpha)^2) \|y\|^2 - 2\alpha(1 - \alpha)x^\top y \\ &= \alpha(1 - \alpha) \|x\|^2 + \alpha(1 - \alpha) \|y\|^2 - 2\alpha(1 - \alpha)x^\top y \\ &= \alpha(1 - \alpha) (\|x\|^2 + \|y\|^2 - 2x^\top y) \\ &= \alpha(1 - \alpha) \|y - x\|^2. \end{aligned}$$

第二行分别用了 $\alpha - \alpha^2 = \alpha(1 - \alpha)$ 和 $(1 - \alpha) - (1 - \alpha)^2 = (1 - \alpha)\alpha$ 。代回便得到题目中的 (ii):

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) - \frac{\mu}{2} \alpha(1 - \alpha) \|y - x\|^2.$$

上述代入和移项都是等价变形, 所以由 (ii) 也能反推出 g 凸, 得到双向蕴含。

(i)⇔(iii): 一阶下界中的二次项

由第 1 题, g 凸等价于

$$g(y) \geq g(x) + \nabla g(x)^\top (y - x).$$

代入 g 和 ∇g , 得到

$$f(y) - \frac{\mu}{2} \|y\|^2 \geq f(x) - \frac{\mu}{2} \|x\|^2 + \nabla f(x)^\top (y - x) - \mu x^\top (y - x).$$

把 $\mu \|y\|^2 / 2$ 移到右侧, 并将三个含 μ 的项合并:

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} (\|y\|^2 - \|x\|^2 - 2x^\top (y - x)).$$

括号内展开为

$$\begin{aligned} \|y\|^2 - \|x\|^2 - 2x^\top (y - x) &= \|y\|^2 - \|x\|^2 - 2x^\top y + 2x^\top x \\ &= \|y\|^2 + \|x\|^2 - 2x^\top y = \|y - x\|^2. \end{aligned}$$

所以得到

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2.$$

逆向进行同样的代数变形便得到 g 的一阶支撑不等式, 再由第 1 题推出 g 凸。

(i)⇔(iv): 梯度的强单调性

由第 1 题, g 凸等价于 ∇g 单调, 即

$$(\nabla g(y) - \nabla g(x))^\top (y - x) \geq 0.$$

先展开梯度差:

$$\nabla g(y) - \nabla g(x) = \nabla f(y) - \mu y - \nabla f(x) + \mu x = \nabla f(y) - \nabla f(x) - \mu(y - x).$$

再与 $y - x$ 做内积:

$$\begin{aligned} (\nabla g(y) - \nabla g(x))^\top (y - x) &= (\nabla f(y) - \nabla f(x))^\top (y - x) - \mu(y - x)^\top (y - x) \\ &= (\nabla f(y) - \nabla f(x))^\top (y - x) - \mu \|y - x\|^2. \end{aligned}$$

因此该表达式非负, 恰好等价于

$$(\nabla f(y) - \nabla f(x))^\top (y - x) \geq \mu \|y - x\|^2.$$

至此, (ii)、(iii)、(iv) 都分别与 (i) 等价, 四个条件的等价性得证。

3 强凸函数的三个推论

本题按原题保留 (ii)、(iii)、(iv) 的编号。为减少长式重复, 记

$$h = y - x, \quad a = \nabla f(y) - \nabla f(x).$$

由第 2 题 (iv), 已有 $a^\top h \geq \mu \|h\|^2$ 。

(ii) 梯度差的范数下界

Cauchy-Schwarz 不等式给出 $a^\top h \leq |a^\top h| \leq \|a\| \|h\|$ 。将它与强单调性连接起来，得到

$$\mu \|h\|^2 \leq a^\top h \leq \|a\| \|h\|.$$

如果 $h = 0$ ，那么 $x = y$ ，也有 $a = 0$ ，所需不等式为 $0 \geq 0$ 。如果 $h \neq 0$ ，则 $\|h\| > 0$ ，两边除以 $\|h\|$ 得

$$\mu \|h\| \leq \|a\|, \quad \text{即} \quad \boxed{\|\nabla f(y) - \nabla f(x)\| \geq \mu \|y - x\|}.$$

这是梯度变化的下界，并非梯度 Lipschitz 连续所要求的上界。

(iii) 用梯度差控制一阶展开的误差

第一步：在 y 处使用强凸下界。第 2 题 (iii) 对任意基点成立。把基点取为 y 、目标点取为 x ：

$$f(x) \geq f(y) + \nabla f(y)^\top (x - y) + \frac{\mu}{2} \|x - y\|^2.$$

由于 $x - y = -h$ ，该式为 $f(x) \geq f(y) - \nabla f(y)^\top h + \mu \|h\|^2/2$ 。移项得到

$$f(y) - f(x) \leq \nabla f(y)^\top h - \frac{\mu}{2} \|h\|^2.$$

两边减去 $\nabla f(x)^\top h$ 后，

$$f(y) - f(x) - \nabla f(x)^\top h \leq (\nabla f(y) - \nabla f(x))^\top h - \frac{\mu}{2} \|h\|^2 = a^\top h - \frac{\mu}{2} \|h\|^2.$$

第二步：把右侧配成一个平方。先展开

$$\|h - a/\mu\|^2 = \|h\|^2 - \frac{2}{\mu} a^\top h + \frac{1}{\mu^2} \|a\|^2.$$

两边乘以 $-\mu/2$ ，得到

$$-\frac{\mu}{2} \|h - a/\mu\|^2 = -\frac{\mu}{2} \|h\|^2 + a^\top h - \frac{1}{2\mu} \|a\|^2.$$

于是

$$a^\top h - \frac{\mu}{2} \|h\|^2 = \frac{1}{2\mu} \|a\|^2 - \frac{\mu}{2} \|h - a/\mu\|^2 \leq \frac{1}{2\mu} \|a\|^2.$$

最后一步因为 $\mu > 0$ 且平方范数非负，所以被减去的项非负。与第一步结合并把 $f(x) + \nabla f(x)^\top h$ 加回去：

$$\boxed{f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{1}{2\mu} \|\nabla f(y) - \nabla f(x)\|^2}.$$

(iv) 内积的上界

由本题 (ii)， $\|h\| \leq \|a\|/\mu$ 。再次使用 Cauchy-Schwarz：

$$a^\top h \leq \|a\| \|h\| \leq \|a\| \frac{\|a\|}{\mu} = \frac{1}{\mu} \|a\|^2.$$

把 a, h 的定义代回即为

$$\boxed{(\nabla f(y) - \nabla f(x))^\top (y - x) \leq \frac{1}{\mu} \|\nabla f(y) - \nabla f(x)\|^2}.$$

这里没有除以可能为零的 $\|a\|$ 或 $\|h\|$ ，因此也覆盖 $x = y$ 的情况。

4 递减步长梯度下降的加权平均收敛率

题设给定 μ -强凸可微函数 f 及其最小值点 x^* ，迭代为

$$x_{t+1} = x_t - \eta_t \nabla f(x_t), \quad \eta_t = \frac{2}{\mu(t+1)}, \quad t = 1, \dots, T.$$

假设仅沿这些迭代点有 $\|\nabla f(x_t)\| \leq L$ 。这里 L 是梯度范数的上界，不是梯度 Lipschitz 常数。记

$$d_t = \|x_t - x^*\|, \quad \Delta_t = f(x_t) - f(x^*) \geq 0, \quad g_t = \nabla f(x_t).$$

证明的顺序是：用强凸性控制梯度内积，展开距离递推，乘上合适权重后求和，最后转成函数值的平均误差。

(a) 梯度内积的下界

在第 2 题 (iii) 的强凸下界中，取基点 x_t 、目标点 x^* ：

$$f(x^*) \geq f(x_t) + g_t^\top (x^* - x_t) + \frac{\mu}{2} \|x^* - x_t\|^2.$$

因为 $x^* - x_t = -(x_t - x^*)$ 且 $\|x^* - x_t\|^2 = d_t^2$ ，所以

$$f(x^*) \geq f(x_t) - g_t^\top (x_t - x^*) + \frac{\mu}{2} d_t^2.$$

把内积项移到左侧、 $f(x^*)$ 移到右侧，得到

$$\boxed{g_t^\top (x_t - x^*) \geq \Delta_t + \frac{\mu}{2} d_t^2.}$$

(b) 展开一次迭代后的平方距离

由更新公式， $x_{t+1} - x^* = (x_t - x^*) - \eta_t g_t$ 。套用 $\|u - v\|^2 = \|u\|^2 - 2u^\top v + \|v\|^2$ ，得到

$$\begin{aligned} d_{t+1}^2 &= \|(x_t - x^*) - \eta_t g_t\|^2 \\ &= d_t^2 - 2\eta_t g_t^\top (x_t - x^*) + \eta_t^2 \|g_t\|^2. \end{aligned}$$

由 (a)，内积至少为 $\Delta_t + \mu d_t^2/2$ 。因为它前面的系数 $-2\eta_t$ 为负，乘上这个系数后不等号反向：

$$-2\eta_t g_t^\top (x_t - x^*) \leq -2\eta_t \left(\Delta_t + \frac{\mu}{2} d_t^2 \right).$$

同时 $\|g_t\|^2 \leq L^2$ 。因此

$$\begin{aligned} d_{t+1}^2 &\leq d_t^2 - 2\eta_t \Delta_t - \mu \eta_t d_t^2 + \eta_t^2 L^2 \\ &= \boxed{(1 - \mu \eta_t) d_t^2 - 2\eta_t \Delta_t + \eta_t^2 L^2}. \end{aligned}$$

(c) 选择权重并逐项抵消

第一步：逐项代入步长。

$$1 - \mu\eta_t = 1 - \frac{2}{t+1} = \frac{t-1}{t+1}, \quad 2\eta_t = \frac{4}{\mu(t+1)}, \quad \eta_t^2 L^2 = \frac{4L^2}{\mu^2(t+1)^2}.$$

所以 (b) 化为

$$d_{t+1}^2 \leq \frac{t-1}{t+1} d_t^2 - \frac{4}{\mu(t+1)} \Delta_t + \frac{4L^2}{\mu^2(t+1)^2}.$$

第二步：使 Δ_t 的系数变成题目所需的 t 。将 Δ_t 项移到左侧， d_{t+1}^2 移到右侧：

$$\frac{4}{\mu(t+1)} \Delta_t \leq \frac{t-1}{t+1} d_t^2 - d_{t+1}^2 + \frac{4L^2}{\mu^2(t+1)^2}.$$

两边乘以正数 $\mu t(t+1)/4$ 。各项系数分别化简为

$$\begin{aligned} \frac{\mu t(t+1)}{4} \frac{4}{\mu(t+1)} &= t, \\ \frac{\mu t(t+1)}{4} \frac{t-1}{t+1} &= \frac{\mu}{4} t(t-1), \\ \frac{\mu t(t+1)}{4} \frac{4L^2}{\mu^2(t+1)^2} &= \frac{tL^2}{\mu(t+1)}. \end{aligned}$$

得到

$$t\Delta_t \leq \frac{\mu}{4} [t(t-1)d_t^2 - t(t+1)d_{t+1}^2] + \frac{tL^2}{\mu(t+1)}.$$

第三步：明确哪些项抵消。记 $A_t = t(t-1)d_t^2$ ，注意 $A_{t+1} = (t+1)t d_{t+1}^2$ ，所以上式的方括号号为 $A_t - A_{t+1}$ 。从 $t=1$ 加到 T ，

$$\begin{aligned} \sum_{t=1}^T (A_t - A_{t+1}) &= (A_1 - A_2) + (A_2 - A_3) + \cdots + (A_T - A_{T+1}) \\ &= A_1 - A_{T+1} \quad (T \geq 2). \end{aligned}$$

$T=1$ 时左侧本身也是 $A_1 - A_2$ ，因此同一结论成立。初项 $A_1 = 1 \cdot 0 \cdot d_1^2 = 0$ ，末项为 $A_{T+1} = T(T+1)d_{T+1}^2$ 。故

$$\sum_{t=1}^T t\Delta_t \leq -\frac{\mu}{4} T(T+1)d_{T+1}^2 + \frac{L^2}{\mu} \sum_{t=1}^T \frac{t}{t+1}.$$

第四步：得到题目要求的上界。距离平方非负，因此第一项不大于零，去掉它只会增大右侧。每个 $t/(t+1) \leq 1$ ，共 T 项，故

$$\boxed{\sum_{t=1}^T t\Delta_t \leq \frac{L^2}{\mu} T.}$$

这个权重同时实现了两个目的：让误差项变成 $t\Delta_t$ ，并让相邻距离项的系数完全匹配。初始距离消失是因为 $A_1 = 0$ ，并非假设初值恰好是最优点。

(d) 从加权误差和得到平均点的收敛率

定义

$$w_t = \frac{2t}{T(T+1)}, \quad \bar{x}_T = \sum_{t=1}^T w_t x_t.$$

先验证它确实是凸组合： $w_t > 0$ ，且由等差数列求和公式，

$$\sum_{t=1}^T w_t = \frac{2}{T(T+1)} \sum_{t=1}^T t = \frac{2}{T(T+1)} \frac{T(T+1)}{2} = 1.$$

强凸性蕴含凸性：从第 2 题 (ii) 去掉右侧非正的二次修正项，就得到普通凸组合不等式。将二点凸性反复应用到有限个点，得到

$$f\left(\sum_{t=1}^T w_t x_t\right) \leq \sum_{t=1}^T w_t f(x_t).$$

由于权重和为 1，也有 $f(x^*) = \sum_{t=1}^T w_t f(x^*)$ 。两式相减：

$$\begin{aligned} f(\bar{x}_T) - f(x^*) &\leq \sum_{t=1}^T w_t (f(x_t) - f(x^*)) \\ &= \frac{2}{T(T+1)} \sum_{t=1}^T t \Delta_t \\ &\leq \frac{2}{T(T+1)} \frac{TL^2}{\mu} = \boxed{\frac{2L^2}{\mu(T+1)}}. \end{aligned}$$

在固定 L 、 μ 的条件下，因 $1/(T+1) \leq 1/T$ ，误差是 $O(1/T)$ 。这个结论针对题目指定的线性加权平均点 $\bar{x}_T$ ；本证明没有把它替换成最后一次迭代点。